

位置分布变化下的 FashionMNIST 分类： 模型结构、Patch 尺度与嵌入方式的对比实验

短学期深度学习课程扩展实验

摘要

本实验研究位置分布变化对 FashionMNIST 分类模型的影响。原始 28×28 图像被放入 64×64 画布。由此构成随机位置分布 A 与固定居中分布 B。在相同的数据划分、训练轮数和模型选择规则下，分别比较 MLP、CNN 与 Vision Transformer (ViT)，比较 ViT 的 patch size 4、8、16，并比较 Conv2d 与 Flatten+Linear 两种 patch embedding。结果显示，CNN 在四项设置中均领先，B→A 为 35.40%。patch size 8 在准确率与训练成本之间较为均衡；两种 patch embedding 的四项准确率差异均不超过 0.61 个百分点。所有模型从 B→B 切换到 B→A 时均明显下降，表明固定位置训练不足以覆盖随机平移分布。由于正式实验只使用一个随机种子，本文将结果解释为受控条件下的观察，不作统计显著性判断。

关键词：FashionMNIST；位置泛化；卷积神经网络；Vision Transformer；Patch Embedding

1 研究问题

图像类别不随平移改变，但分类器未必具备稳定的平移泛化能力。课程基础任务采用 ViT 处理位置可变 FashionMNIST；本实验只讨论三项扩展比较，不重复基础模型的实现过程。研究问题是：不同结构的归纳偏置是否影响位置泛化；更细的 patch 是否改善小图像分类；两种常用 patch embedding 实现是否产生可测的性能差异。

- 结构比较：MLP、CNN、patch-16 ViT。
- Patch 尺度比较：在相同 ViT 主体下采用 patch size 4、8、16。
- 嵌入比较：在 patch size 16 下采用 Conv2d 或 Flatten+Linear。

评价同时报告同分布结果 A→A、B→B 和跨分布结果 A→B、B→A。箭头左侧为训练分布，右侧为测试分布。B→A 是最具区分度的设置：模型只见过居中样本，却需要识别随机位置样本。

2 数据与实验方法

2.1 数据构造与评价设置

FashionMNIST 官方训练集含 60,000 张图像，按固定随机顺序划分为 54,000 个训练样本和 6,000 个验证样本；官方测试集含 10,000 个样本。每张 28×28 灰度图像均嵌入 64×64 黑色画布。分布 A 对每个样本独立采样合法平移，分布 B 将图像固定在画布中心。类别标签与原始数据保持一致。

设置	训练分布	测试分布	评价含义
A→A	随机位置	随机位置	随机位置同分布性能
B→B	固定居中	固定居中	固定位置同分布性能
A→B	随机位置	固定居中	随机训练对中心位置的覆盖
B→A	固定居中	随机位置	固定训练对平移分布的泛化

表 1 四种训练—测试设置

2.2 训练协议

所有配置采用 AdamW，学习率 0.001，权重衰减 0.0001，batch size 64，训练 15 个 epoch，随机种子 42。每个配置分别训练一个 A 模型和一个 B 模型；最佳 checkpoint 由对应分布的验证准确率选择，测试集仅用于最终评价。这样既避免四个设置各自重复训练，也避免以测试集选择 epoch。

训练启用自动混合精度，但未开启完全确定性 CUDA 算法。正式记录来自 Python 3.12.13、PyTorch 2.11.0+cu128、NVIDIA GeForce RTX 5070 Laptop GPU。运行时间用于比较本机同一批实验的相对成本，不作为跨硬件基准。

2.3 控制变量与模型

模型结构比较使用 MLP、两层卷积 CNN 和 patch-16 ViT。Patch 尺度实验只改变 patch size，保持 embedding dimension、Transformer 深度和注意力头数不变。Patch embedding 实验固定 patch size 16，并保持参数量一致。不同结构的参数量未强制匹配，因此模型结构比较反映的是完整配置差异，而非纯粹的参数效率比较。

实验程序保存训练历史、最佳验证准确率、最终测试指标、配置清单和绘图数据。图表全部由保存的 CSV/JSON 记录生成，报告数值不依赖人工抄录。

3 总体结果

表 2 汇总六个配置的最终测试准确率。B→B 普遍高于 A→A，说明固定居中数据的变化范围更小；A→B 与 A→A 接近，说明随机位置训练通常能够覆盖中心位置。相反，B→A 对所有配置都困难，且准确率远低于对应的 B→B。

配置	参数量	A→A	B→B	A→B	B→A
MLP	542,474	71.89%	89.57%	71.97%	13.99%
CNN	205,994	92.35%	93.14%	92.87%	35.40%
ViT, patch 16	829,834	80.07%	88.87%	80.97%	16.91%
ViT, patch 8	811,402	80.40%	88.27%	81.13%	18.81%
ViT, patch 4	829,834	75.28%	87.22%	74.97%	17.02%
ViT, Linear patch 16	829,834	79.67%	88.80%	80.48%	16.30%

表 2 六个配置在四种位置设置下的测试准确率




图 1 六种配置在 A、B 验证集上的训练过程。每条曲线对应一个独立训练模型。

验证曲线在 15 个 epoch 内整体趋于平稳，没有持续发散。B 分布的曲线通常更快达到较高准确率，这与其只包含中心位置、样本变化较少一致。A 分布同时包含类别差异和位置变化，训练准确率较低并不直接表示模型失效，而是反映任务范围扩大。后续比较因此以同一设置内的模型差异为主，不将 A 与 B 的绝对准确率简单等同。

4 对比一：MLP、CNN 与 ViT




图 2 MLP、CNN 与 patch-16 ViT 在四种位置设置下的测试准确率。

CNN 在四项设置中均为最高：A→A 92.35%，B→B 93.14%，A→B 92.87%，B→A 35.40%。MLP 的 A→A 与 A→B 均约为 72%；patch-16 ViT 对应结果约为 80% 和 81%。在随机位置训练的两个设置中，CNN 比 patch-16 ViT 高 12 个百分点左右，差异在本次实验中具有明确的量级。




图 3 固定位置训练后的性能变化；下降量定义为 B→B 减 B→A。

从 B→B 切换到 B→A 后，MLP、CNN 和 ViT 分别下降 75.58、57.74 和 71.96 个百分点。CNN 的下降仍然很大，但 B→A 准确率比 MLP 高 21.41 个百分点，比 patch-16 ViT 高 18.49 个百分点。局部卷积核在空间位置之间共享参数，为平移后的局部模式提供了直接复用机制；MLP 对不同像素位置使用不同连接；当前 ViT 使用可学习绝对位置编码，token 表征与训练位置关联更强。这些结构性质与观察到的相对顺序一致，但单次实验不能把全部差异唯一归因于某一个组件。

5 对比二：ViT Patch 尺度




图 4 保持 ViT 主体结构不变时，patch size 4、8、16 的测试准确率。

patch size 8 在 A→A、A→B 与 B→A 上分别得到 80.40%、81.13% 和 18.81%，是三种尺度中的最高值。patch size 16 在 B→B 上最高，为 88.87%。patch size 4 在 A→A 与 A→B 上下降到 75.28% 和 74.97%，未获得更细粒度所预期的准确率收益。三种设置的参数量接近，因此差异主要伴随 token 数和优化过程变化。

序列长度与训练成本

在 64×64 画布上，patch size 4、8、16 分别产生 256、64、16 个图像 token。自注意力需要建立 token 两两关系，其矩阵元素数分别为 65,536、4,096 和 256。这一理论规模不等同于端到端时间，因为数据加载、线性层和 GPU 并行效率也占用时间，但可解释细粒度 patch 的额外计算压力。

本机训练 A、B 两个模型的累计时间分别为：patch 4 为 8.93 分钟，patch 8 为 7.36 分钟，patch 16 为 6.46 分钟。patch size 4 最慢，但准确率没有提高。当前任务中，patch size 8 避免了 patch 16 的较粗空间划分，又不承担 patch 4 的长序列成本，因而是更合理的折中。该判断只适用于当前画布、模型深度和训练预算。

更小 patch 并不必然带来更好结果。细粒度输入增加了可用空间信息，也增加了序列长度和优化难度；当训练轮数固定时，后者可能抵消前者。若要判断 patch 4 是否受训练不足影响，需要进一步增加训练预算或调整学习率，而不能只依据单一设置外推。

6 对比三：Patch Embedding 实现




图 5 patch size 16 时，Conv2d 与 Flatten+Linear 的测试准确率。

Conv2d 版本在 A→A、B→B、A→B、B→A 上分别为 80.07%、88.87%、80.97%、16.91%；Flatten+Linear 版本分别为 79.67%、88.80%、80.48%、16.30%。四项绝对差异为 0.40、0.07、0.49、0.61 个百分点，最大差异为 0.61 个百分点。两者参数量均为 829,834，累计训练时间分别为 6.46 和 7.25 分钟。

等价关系与结果解释

当卷积核大小与步长都等于 patch size、patch 之间不重叠时，Conv2d 对每个 patch 应用同一组卷积核。将卷积核展平后，可得到从 patch_dim 到 embed_dim 的线性映射；这与对每个展平 patch 共享同一个 Linear 层在表达形式上等价。项目测试通过重排同一组权重，验证了两种前向结果在浮点误差范围内一致。

训练结果中的小差异可能来自参数初始化后的随机优化路径、底层算子和浮点计算顺序。由于只运行一个随机种子，0.61 个百分点不足以支持稳定优劣判断。就当前非重叠 patch 设置而言，选择哪种实现应更多考虑代码接口、可读性和后续扩展需求。若采用重叠 patch、卷积前处理或不同归一化，两种方案才会不再对应同一个简单线性映射。

因此，本组实验的主要结果不是某种实现提高了准确率，而是实测结果与理论等价关系相符：在控制参数量和 patch 划分后，embedding 写法本身没有形成可辨认的性能差距。

7 讨论

7.1 三组结果的共同指向

三组比较共同表明，位置泛化的主要困难不是固定位置样本本身的分类，而是训练分布是否覆盖测试时可能出现的位置。B→B 中所有模型都取得较高准确率，但这一结果不能预测 B→A。CNN 的局部参数共享改善了跨位置复用，仍无法替代随机位置训练。对 ViT 而言，增加 token 数也没有自动解决位置泛化。A→B 接近 A→A，则说明随机平移训练能够覆盖中心位置。若继续提高 B→A，更直接的方向是平移增强、相对位置编码或显式平移不变设计，而不是只增加参数量。

7.2 与同学项目的外部参考

同学仓库 [kicious/translated-fashion-mnist-vit](#) 在 commit 943fa7b68730bc8ea7786bb41c7b8dc1d488883a 公开的四项 reported best 为 79.35%、88.22%、80.48%、19.37%。本实验 patch-16 ViT 为 80.07%、88.87%、80.97%、16.91%。前三项差异小于 1 个百分点，B→A 差 2.46 个百分点，数值量级基本一致。

两组记录不构成严格对照。同学项目在每个 epoch 使用测试集评价并保留最佳记录；本实验使用验证集选择 checkpoint，测试集只用于最终评价。模型选择规则、训练实现和随机过程均不同，因此这里仅检查结果是否处于相近范围，不据此判断项目优劣。

7.3 局限性

- 正式结果仅包含 seed 42，未报告均值、标准差和显著性检验。
- MLP、CNN 与 ViT 参数量不同，结构比较同时包含容量差异。
- CUDA 未开启完全确定性；小于 1 个百分点的差异不作强解释。
- 训练时间来自单一笔记本 GPU，只能用于本次实验内部比较。
- 数据只包含平移变化，结论不直接外推到旋转、缩放或自然图像。

8 结论与复现说明

在统一实验协议下，CNN 是三类结构中表现最好的配置：四项准确率均为最高，且 B→A 达到 35.40%。其局部感受野和跨位置参数共享与较强的位置泛化相符，但从 B→B 到 B→A 仍下降 57.74 个百分点，说明结构先验不能弥补训练位置覆盖不足。

ViT 的 patch size 8 在本实验中取得更好的精度—成本折中。patch size 4 产生 256 个 token，训练时间增加到 8.93 分钟，却未获得准确率收益。Conv2d 与 Flatten+Linear patch embedding 的最大准确率差异为 0.61 个百分点，且两者在非重叠 patch 条件下具有等价的线性表达，本次结果不支持其中一种稳定优于另一种。对该任务，训练位置覆盖范围比单纯增加 token 数更关键；后续应优先增加随机种子，并评估相对位置编码或平移增强。

复现：结构化提交包包含代码、指标和核心图表，不含原始数据与 checkpoint。解压并安装依赖后，运行 `python VERIFY.py` 可检查文件结构、正式指标、8 项单元测试和命令行入口。

参考资料

- [1] Xiao H., Rasul K., Vollgraf R. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747, 2017.
- [2] Dosovitskiy A., Beyer L., Kolesnikov A., et al. An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale. ICLR, 2021.
- [3] 课程材料：《位置可变的 FashionMNIST 数据生成》《神经网络》《实验实现》《关于作业与实验报告》，2026。
- [4] [kicious/translated-fashion-mnist-vit](#), commit 943fa7b68730bc8ea7786bb41c7b8dc1d488883a.